

Conferencia 3 Predicción de interacciones proteína-proteína

Material Complementario

En la conferencia pasada estudiamos la estructura 3D de las proteínas y vimos las técnicas experimentales y métodos bioinformáticos que pueden usarse para obtener dicha estructura. Sin embargo, hasta ahora solo hemos analizado la estructura de las proteínas individualmente, lo que se conoce como **estructura terciaria**. En la naturaleza, las proteínas rara vez actúan de forma aislada. Muchas proteínas interactúan con otras proteínas mediante la formación de los llamados complejos proteína-proteína. A la disposición de diferentes cadenas proteicas para formar un complejo proteína-proteína se denomina **estructura cuaternaria de las proteínas**.

Los complejos proteína-proteína resultan cruciales para una gran cantidad de procesos biológicos, incluidos pero no limitados a señalización celular, Regulación enzimática, Regulación génica, Complejos enzimáticos, Inmunidad y la ingeniería de proteínas, entre otros. En la diapositiva 4 pueden observar 3 ejemplos de complejos proteína-proteína que seguramente hayan escuchado con anterioridad en la carrera: la hemoglobina (formada por cuatro cadenas proteicas idénticas), las inmunoglobulinas (formadas por dos cadenas pesadas y dos ligeras), y el complejo de la piruvato deshidrogenasa (formado por decenas de copias de 3 proteínas diferentes)

El conocimiento de la estructura cuaternaria de un complejo es muy importante para entender su mecanismo de acción y su función. Usando las coordenadas tridimensionales de los complejos proteicos los investigadores pueden realizar predicciones mediante diferentes métodos bioinformáticos como la dinámica molecular. Estas predicciones son muy útiles en diferentes campos como la ingeniería de proteínas o los tratamientos médicos, por lo que se puede afirmar que el conocimiento de la estructura 3D de complejos proteína-proteína tiene una gran utilidad práctica.

Para obtener la estructura 3D de un complejo podemos usar algunas de las técnicas experimentales que vimos en la conferencia anterior. ¿Recuerda cuáles eran? Sin embargo, resolver la estructura 3D de un complejo proteína-proteína mediante alguna de estas técnicas es un proceso muy difícil debido a las limitaciones de cada técnica:

Cristalografía de rayos X:

Como vimos en la conferencia anterior, cristalizar una proteína en su conformación nativa es un proceso difícil, que se vuelve más complicado en el caso de complejos proteína-proteína. Muchas combinaciones de proteínas nunca llegan a cristalizar, y muchas otras cristalizan pero sin formar complejos con su conformación nativa.

Resonancia Magnética Nuclear (RMN):

La mayoría de los complejos proteína-proteína conocidos presentan alto peso molecular, lo cual los hace inviable para su resolución mediante RMN. Recordemos que esta técnica solo puede ser aplicada a proteínas de bajo peso molecular, lo cual limita la aplicación de RMN a algunos complejos diméricos de pequeño tamaño.

Criomicroscopía electrónica:

Contrario a lo que sucede en RMN, la criomicroscopía electrónica solo puede ser aplicada a complejos proteicos de gran tamaño (mayores de 100 kDa). Sin embargo, el gran desarrollo que ha experimentado esta técnica en los últimos años ha permitido que sea aplicada a un gran número de complejos multiproteicos que no habían podido ser cristalizados anteriormente. Se espera que el número de complejos resueltos mediante esta técnica aumente notablemente en los próximos años, aunque la limitante del peso molecular sigue siendo un obstáculo para la resolución de muchos complejos de mediano tamaño.

Debido al alto costo y las limitaciones de las técnicas experimentales, el número de complejos proteicos con estructura 3D resuelta es muy inferior al número de complejos que pueden formarse en la naturaleza. De acuerdo a la base de datos BioGrid, hasta septiembre de 2021 se habían detectado **1.684.710** interacciones físicas entre proteínas. En contraste, el PDB dispone de **182.418** estructuras 3D resueltas, de las cuales solo **36.669** corresponden a complejos proteína-proteína, lo cual representa el **2.17%** de todas las interacciones proteína-proteína conocidas. De aquí que exista una necesidad de predecir la estructura 3D de los complejos proteicos mediante métodos bioinformáticos.

Los métodos bioinformáticos de predicción de estructura 3D se han ido ganando notoriedad en los últimos años, debido al interés de los científicos por comprender y modificar las interacciones proteína-proteína. Estos métodos son atractivos en la actualidad debido a que suelen ser rápidos, fáciles de usar y consumen pocos recursos computacionales, en comparación con las técnicas experimentales que son mucho más complejas y costosas. Además, como ventaja adicional, para predecir de las coordenadas 3D del complejo mediante métodos bioinformáticos solo se requiere conocer las coordenadas 3D de las proteínas individuales (o de alguno de sus homólogos).

Antes de comenzar a estudiar los métodos bioinformáticos, analicemos brevemente las bases de la interacción entre proteínas.

El modelo biofísico más sencillo de un mecanismo de unión proteína-proteína es el modelo llave-cerradura. Este mecanismo está basado en el modelo propuesto por Emil Fisher en 1894, y plantea que la unión entre dos proteínas se produce debido a la complementariedad de forma de interacciones en el sitio de unión entre ambas proteínas. En este modelo, las proteínas son consideradas como cuerpos rígidos y se asume que no se producen cambios en la zona de interacción durante la unión de la proteína. Este modelo es sencillo y fácil de comprender, sin embargo, no capta la naturaleza dinámica de las proteínas. La estructura de las proteínas es flexible, y esta flexibilidad también se pone de manifiesto durante la unión entre proteínas.

En vista de las limitaciones del modelo llave-cerradura, se han propuesto nuevos mecanismos de unión que sí tienen en cuenta la flexibilidad de las proteínas. En la actualidad, los dos modelos más aceptados son la pre-selección conformacional (CS) y el encaje inducido (IF). Por lo general, se considera que la formación de un complejo proteico puede producirse por cualquiera de los dos mecanismos.

En el caso del modelo de pre-selección conformacional, se considera que una de las proteínas oscila normalmente entre diferentes conformaciones. La unión de la otra proteína solamente está

favorecida en una de estas conformaciones. Una vez unida, la proteína inicial deja de oscilar y se estabiliza en esa conformación, formándose así el complejo.

En el caso del modelo de encaje inducido, se considera que ambas proteínas experimentan una unión inicial débil, seguida de un cambio conformacional que incrementa la afinidad entre ambas proteínas y permite la formación del complejo final.

Observen que en ambos mecanismos de unión las proteínas experimentan cambios conformacionales. La diferencia radica en que en el caso de la preselección conformacional dichos cambios ocurren *antes* de la unión, y en el caso del encaje inducido, *después* de la unión.

Hasta ahora hemos hablado de los sitios de unión entre proteínas, pero no hemos visto sus detalles. Los sitios de interacción entre proteínas pueden ser muy variados e ir desde superficies planas a bolsillos y hendiduras. En todos los casos, formación del complejo se estabiliza mediante interacciones entre los aminoácidos de ambas proteínas, fundamentalmente interacciones hidrofóbicas, electrostáticas o puentes de hidrógeno. Sin embargo, no todos los residuos de la interfaz de interacción proteína-proteína contribuyen de igual manera a la energía libre de unión. Se ha demostrado que por lo general solo unos pocos residuos contribuyen notablemente a la estabilidad del complejo. Estos son llamados residuos de interacción (*hotspot residues*) y son de gran importancia para comprender y modificar las interacciones entre proteínas.

Como mencionamos anteriormente, los métodos bioinformáticos permiten predecir la estructura 3D de los complejos proteína-proteína a partir de sus componentes individuales. En la conferencia de hoy vamos a analizar dos métodos de predicción muy utilizados en la actualidad: la **Modelación basada en complejos homólogos** y el **acoplamiento molecular (docking) proteína-proteína**.

En la **modelación basada en complejos homólogos**, el objetivo es predecir la estructura de un complejo proteína-proteína usando las coordenadas de un complejo de estructura resuelta (complejo molde). Usualmente, el complejo molde está formado por proteínas homólogas a las proteínas de interés, de manera que se asume que existe conservación de la estructura y del modo de unión. Al igual que en modelación por homología, mientras mayor sea la identidad de secuencia de las proteínas del complejo molde, mejor será la calidad del modelo final.

La modelación en sí puede ser realizada mediante modelación por homología (de forma similar a como vimos en la conferencia anterior) o mediante superposición de estructuras. En este último caso, se superponen las coordenadas del backbone de la proteína de interés sobre el backbone de la proteína homóloga en el complejo molde de manera el valor de RMSD sea mínimo. Cuando se usa, modelación por homología no es necesario conocer la estructura 3D de las proteínas de interés, ya que estas son modeladas a partir de sus homólogos en el complejo molde, pero en el caso de la superposición estructural sí se requiere conocer la estructura 3D para poder hacer la superposición.

Analicemos brevemente cómo se realiza la **modelación basada en complejos homólogos**. Supongamos que tenemos dos proteínas llamadas **A** y **B** (diapositiva 14) y queremos predecir la estructura 3D del complejo formado por la unión de ambas proteínas (complejo **A:B**). Para poder construir el modelo, buscamos en la base de datos PDB complejos formados por proteínas homólogas de nuestras proteínas de interés y sean similares al complejo que queremos modelar.

Un complejo molde ideal (diapositiva 15) contiene una de las proteínas de interés (**A**) y un homólogo de la otra proteína (**C**), lo cual simplifica el problema a la modelación de una sola proteína (**B**). Una vez seleccionado el complejo molde, se procede a modelar la proteína **B** mediante modelación por homología (si no hubiera estructura resuelta) o superposición estructural (si hubiera una estructura resuelta), usando a **C** como molde. Una vez modelado el complejo, se realiza un paso de refinamiento mediante minimización de energía o simulaciones de dinámica molecular a fin de eliminar interacciones desfavorables y optimizar la estructura del modelo, de forma similar a la modelación de estructuras 3D.

Si durante la búsqueda del molde no apareciera ningún complejo que contenga al menos una de las proteínas de interés, se puede utilizar un complejo molde que contenga solamente proteínas homólogas. En este caso se modelan o superponen ambas proteínas y se debe poner especial atención a la fase de refinamiento, ya que al haber dos proteínas modeladas se aumenta el riesgo de que haya problemas en la estructura del complejo.

La modelación basada en complejos homólogos es muy útil cuando existen complejos homólogos en el PDB similares a nuestro complejo de interés. Sin embargo, esto también es su principal limitación, ya que como vimos hay poca representación de complejos proteicos en el PDB debido lo difícil que resulta resolver su estructura de manera experimental. Otra limitación es que el hecho de que dos complejos estén formados por proteínas homólogas no garantiza que el modo de unión sea similar. Dentro de una misma familia puede haber proteínas con diferentes afinidades y modos de unión. Un elemento importante a la hora de buscar complejos homólogos es la conservación de residuos en el sitio de unión. Si la identidad de secuencia de la zona de interacción del complejo molde es baja, la calidad del modelo resultante tendrá será poco fiable, incluso si la identidad de secuencia en el resto del complejo es alta.

En general, antes de seleccionar un complejo como molde debemos revisar siempre si existe conservación del sitio de unión, y si hay alguna evidencia experimental que avale que este complejo molde es similar al complejo que queremos modelar.

Ahora, ¿qué podemos hacer si no existe ningún complejo homólogo que podamos usar como molde? En estos casos podemos recurrir a otro tipo de métodos muy usados en la actualidad: **los métodos de acoplamiento molecular (docking) proteína-proteína**. Estos métodos pueden predecir las coordenadas del complejo proteína-proteína a partir de las coordenadas de sus componentes individuales. Estas coordenadas pueden provenir de una estructura resuelta mediante técnicas experimentales, o de un modelo predicho mediante alguna de las técnicas que vimos en la clase pasada.

La mayoría de los métodos de acoplamiento molecular modernos solo permiten predecir la unión de dos proteínas a la vez. En este caso, una de las proteínas (usualmente la de mayor tamaño) se denomina receptor y la otra (usualmente más pequeña), se denomina ligando. El principio detrás de estos métodos es generar múltiples conformaciones posibles del complejo receptor-ligando, evaluar las conformaciones en función de la complementariedad entre ambas proteínas, y luego seleccionar **las conformaciones más probables** (aquellas que tienen más probabilidades de corresponder con la estructura nativa del complejo)

Un procedimiento típico de docking proteína-proteína consta de tres fases: 1) una **fase de búsqueda**, donde se generan muchos posibles complejos proteína-ligando 2) una **fase de muestreo** donde se asigna una puntuación a cada uno de los complejos posibles para luego seleccionar los complejos de mejor puntuación, y 3) una **fase de filtrado**, donde se refinan los complejos seleccionados en el paso anterior, se vuelven a puntuar y se escogen los complejos de mejor puntuación como modelos finales. Dependiendo del procedimiento, es posible añadir una fase adicional de refinado usando algún método de mecánica molecular como dinámica molecular.

Todo algoritmo de modelación empieza con la fase de búsqueda. Durante esta fase se aplica un método de búsqueda para generar una gran cantidad de posibles complejos receptor ligando. El método de búsqueda es un algoritmo sistemático que usa transformaciones espaciales para generar múltiples conformaciones posibles del complejo. El procedimiento general consiste en mantener las coordenadas de una de las proteínas fijas (receptor) y aplicar transformaciones espaciales de rotación y traslación a la otra proteína (ligando) de manera que ambas proteínas siempre estén en contacto. Cada vez que se realiza una evaluación se guardan las coordenadas del complejo generado para su posterior evaluación. Durante esta fase no se realiza ninguna evaluación, el programa solo trata de generar tantas posibles conformaciones como le sea posible.

En general, los métodos de búsqueda se pueden clasificar en dos grandes grupos: **métodos de búsqueda locales**, y **métodos de búsqueda globales**.

Los métodos de búsqueda locales son útiles cuando se conoce la zona de interacción entre ambas proteínas (o al menos, la zona de interacción del receptor). Estos métodos empiezan por la generación de una conformación inicial basada en los conocimientos que se tiene del sitio de interacción. La generación de los nuevos complejos posibles se realiza mediante transformaciones espaciales de esta conformación inicial y se restringe a zonas cercanas espacialmente. Debido a esta restricción, la cantidad de complejos a generar por lo general no es muy grande, lo que permite tratar a las proteínas como estructuras flexibles y usar algoritmos que serían muy costosos computacionalmente bajo otras condiciones. Algunos de estos algoritmos usados son la minimización de energía, las simulaciones de monte Carlo o la dinámica molecular.

La principal limitación de los métodos de búsqueda locales radica en que en muchas ocasiones no se conoce con exactitud la zona de interacción entre las proteínas, lo cual hace que el método sea inusable en estos casos.

En la diapositiva 22 se puede apreciar un esquema de cómo funciona el método de búsqueda local para el caso del programa RosettaDock. Primero, se comienza con la generación de la conformación inicial, luego, se aplican transformaciones espaciales (mayormente traslación) y se optimizan las cadenas laterales del ligando para generar múltiples conformaciones del complejo. En este caso, las coordenadas del receptor son iguales para todos los complejos generados, solo varían las coordenadas del ligando. Las coordenadas de los posibles complejos son usadas en las fases de muestreo y filtrado para poder generar el modelo final.

Los métodos de búsqueda locales suelen dar resultados precisos, pero la necesidad de conocer la zona de interacción puede ser una limitante en el caso de proteínas poco estudiadas. Para solventar este problema existen los métodos de **búsqueda globales**. En estos métodos, el ligando se somete a transformaciones espaciales de rotación y traslación por **toda la superficie del receptor**. En este

caso no es necesario tener ningún conocimiento del sitio de unión, el programa se encargará de analizar todos los sitios posibles. Dado que la superficie a evaluar es mucho mayor que en los métodos de búsqueda globales, los algoritmos que se utilizan para generar los complejos usan aproximaciones a fin de reducir el costo computacional. Por ejemplo, el backbone de las proteínas se considera rígido (se asume que no hay cambios conformacionales) y solo se considera la flexibilidad de las cadenas laterales en algunos casos. Otro elemento que permite reducir el costo computacional es el uso de algoritmos de búsqueda que permitan obtener resultados rápidos pero aproximados, como la correlación basada en Transformadas Rápidas de Fourier, la búsqueda Aleatorizada y el ajuste de forma local.

Observe que al no considerar la flexibilidad de las proteínas, los métodos de búsqueda local asumen una unión tipo llave-cerradura sin cambios conformacionales durante la unión. A fin de reducir los problemas que esto pueda causar, se recomienda, siempre que sea posible, usar estructuras iniciales del receptor y el ligando provenientes de otros complejos proteicos, ya que esto garantiza que ambas proteínas estén en la conformación que adoptan durante la unión a proteínas.

Como dato adicional, es posible usar información experimental (como residuos importantes para la interacción) a fin de reducir el espacio de búsqueda e incrementar la precisión de los resultados. La inclusión de información experimental no es obligatoria, pero puede ayudar en la predicción de complejos más cercanos a la realidad.

En la diapositiva 24 se observa un esquema simplificado de cómo funcionan los métodos locales. Observe que la estructura del receptor se mantiene fija mientras el ligando se rota y traslada por toda la superficie de la proteína. Cada vez que se determina un posible complejo, las coordenadas de este complejo son guardadas para una vez terminada la búsqueda proceder a la siguiente fase: **la fase de muestreo**.

Como ya vimos, en la fase de búsqueda se generan una gran cantidad de posibles complejos. Sin embargo la mayoría de estos complejos presentan interacciones desfavorables, y por tanto corresponden a uniones muy poco probables. A fin de determinar que complejos son los más cercanos a la realidad se debe someter todas las conformaciones generadas durante la fase de búsqueda a una **fase de muestreo**. Durante esta fase, se va a puntuar cada uno de los posibles complejos empleando una **función de puntuación**. Una vez puntuadas todas las conformaciones, se eligen las conformaciones de mejor puntuación y se pasa a la siguiente fase.

Del tipo de función de puntuación empleada va a depender en gran medida los resultados del docking. Cada programa de docking proteína-proteína usa su propia función de puntuación, lo que hace que en la actualidad exista una amplia variedad de las mismas. Las funciones de puntuación pueden clasificarse de acuerdo a su origen en: 1) **Estadísticas**: diseñada a partir de análisis estadísticos de los residuos involucrados en los complejos proteicos con estructura 3D conocida. 2) **Empíricas**: diseñadas a partir de resultados experimentales de cálculos de afinidad entre proteínas y 3) **Basadas en campos de fuerza**: diseñadas a partir del conocimiento de las interacciones a nivel atómico y entre moléculas. Las funciones de puntuación también pueden clasificarse de acuerdo a los factores que evalúan, por ejemplo: Complementariedad de forma, Interacciones hidrofóbicas y electrostáticas, y la Energía de solvatación.

Veamos algunos ejemplos de función de puntuación empleados por algunos programas:

La complementariedad de forma geométrica es un método extremadamente simple para analizar interacciones entre proteínas. Básicamente, analiza cuan complementarias son las superficies de dos proteínas desde un punto de vista puramente geométrico, sin tener en cuenta las propiedades de los aminoácidos presentes en dichas superficies. Debido a su sencillez, este método es muy rápido y poco costoso computacionalmente. Sin embargo, los resultados son poco fiables y puede fallar en casos donde las interacciones electrostáticas o por puente de hidrógeno sean importantes para la formación del complejo.

Una de las funciones de puntuación más usadas en la actualidad es la basada en interacciones electrostáticas e hidrofóbicas. En este caso, no solo se tiene en cuenta la complementariedad de forma, sino también los residuos involucrados en la interfaz de interacción. Por lo general, estos métodos son de origen empírico o estadístico y usan modelos simplificados de residuos. Esto significa que los residuos se representan como puntos en el espacio con distintas propiedades según el tipo de residuo, como la carga o la hidrofobicidad. Las interacciones se evalúan en función de los propiedades de residuos que estén en contacto. Las interacciones favorables (residuos polares cercanos, carga positiva cerca de carga negativa) reciben la mayor puntuación. Este tipo de función de puntuación permite una evaluación relativamente rápida de las interacciones entre proteínas con una precisión bastante aceptable.

En contraste, las funciones de puntuación basadas en campos de fuerza sí representan la totalidad de los residuos residuo a la hora de calcular las interacciones. En este caso, la puntuación va a estar determinada por los pares de interacciones que se establecen entre todos los residuos de la zona de contacto. Debido a que se consideran todos los átomos del residuo, el costo computacional de este tipo de métodos es muy alto, aunque esto también significa que pueden lograr una mayor precisión que las otras funciones de puntuación analizadas.

Una vez asignada una puntuación a cada uno de los complejos generados, se hace una selección de los mejores complejos (usualmente, los de mayor puntuación) y estos pasan a la **fase de filtrado**.

El objetivo de la fase de filtrado es optimizar y volver a evaluar los complejos receptor-ligando elegidos en la fase de muestreo para así seleccionar los modelos finales. El primer paso normalmente consiste en refinar la estructura de los complejos seleccionados en la fase de muestreo mediante métodos de mecánica molecular como Minimización de energía, simulaciones de Monte-Carlo o simulaciones de dinámica molecular. Estos métodos son costosos computacionalmente ya que tienen en cuenta la flexibilidad estructural de las proteínas, pero permiten compensar parcialmente los artefactos generados al tratar al receptor y al ligando como cuerpos rígidos en la fase de muestreo.

Una vez refinado los complejos, se procede a hacer una re-evaluación de los mismos utilizando una función de puntuación diferente a la usada en la fase de muestreo. Esta nueva función de puntuación usualmente es más precisa pero más costosa computacionalmente que la usada en la fase anterior. La razón por la cual en la fase de filtrado se usan métodos más costosos computacionalmente que en la fase de muestreo está dado porque en la fase de filtrado el número de complejos a evaluar es mucho menor que en la fase de muestreo.

Luego de la re-evaluación de los complejos, se hace una selección final y se reportan los mejores 5-10 complejos como **modelos finales**.

El grado de similitud en la estructura de los **modelos finales** reportados suelen variar dependiendo del complejo que estemos modelando, pero por lo general los programas suelen reportar varios complejos con conformaciones muy diferentes. Seleccionar cual complejo se corresponde mejor con la realidad suele estar a cargo del investigador, que debe revisar cada complejo a fin de determinar su calidad. Para esto se suelen evaluar parámetros ya conocidos mediante técnicas experimentales, como la distancia entre aminoácidos, la exposición de residuos al solvente y los residuos de contacto, entre otros. Una variante fácil de evaluar es la predicción de los residuos importantes para la interacción del complejo modelado mediante scanning de alanina, la cual explicaremos en la próxima diapositiva. Finalmente, una técnica bastante utilizada para poder seleccionar el mejor complejo es la predicción de la energía libre de unión (ΔG) del complejo mediante simulaciones de dinámica molecular. Esta técnica permite predecir la energía de unión con bastante precisión, la cual puede compararse luego con la K_i calculada experimentalmente. La predicción de $\Delta G_{\text{unión}}$ usando simulaciones de dinámica molecular será explicada con mayor detalle en próximas conferencias.

El scanning de alanina es una técnica bastante utilizada para la predicción de los residuos importantes (*hotspots residues*) en los complejos proteína-proteína. Esta técnica puede ser aplicada a los complejos obtenidos mediante docking proteína-proteína para la comparación con resultados experimentales o la predicción de aminoácidos que pueden ser mutados para alterar la estabilidad del complejo.

En esencia, el scanning de alanina consiste en mutar los residuos de la interfaz de interacción por alaninas de manera secuencial. Al mutar un residuo por alanina, se elimina la mayor parte de su cadena lateral y se reducen las interacciones que el residuo puede establecer. La diferencia entre las interacciones que se establecen antes y después de la mutación puede ser calculada para determinar cuánto contribuye el residuo a la unión entre ambas proteínas,

El procedimiento del scanning de alanina comienza con la predicción de la energía de interacción (ΔG) entre las dos proteínas del complejo usando una función de puntuación. Luego, se sustituye uno de los residuos de la interfaz por una alanina y se recalcula la energía de interacción. La diferencia resultante entre la energía del complejo original y la energía del complejo mutado ($\Delta\Delta G$) se utiliza para determinar la contribución del residuo. Si $\Delta\Delta G$ es cercana a 0, el residuo no es importante para la interacción, si $\Delta\Delta G$ es menor que 0 el residuo contribuye favorablemente a la interacción, y si $\Delta\Delta G$ es positiva el residuo es desfavorable para la interacción. Una vez calculado el $\Delta\Delta G$ del residuo mutado, se vuelve al complejo inicial (sin mutar), se muta un residuo diferente de la interfaz por una alanina y se calcula el $\Delta\Delta G$ nuevamente. El proceso se repite para todos los residuos de la interacción, y de esta manera se puede determinar cuáles son los aminoácidos con $\Delta\Delta G$ más negativo, que en principio corresponden a los residuos importante de la interacción (*hotspots*).

Luego de analizar el scanning de alanina pudiera surgir la duda ¿Por qué se escoge a la alanina y no a la glicina para realizar el scanning, siendo la glicina el aminoácido más pequeño? La alanina es el segundo aminoácido más pequeño y posee con una cadena corta que, al igual que la glicina, tiene poca capacidad de interacción con otras moléculas. Debido a esto, en ingeniería de proteínas se suele usar la alanina cuando se quiere substituir algún residuo importante por otro que no establezca interacciones. Al usar alanina en el scanning bioinformático, se asegura que los

resultados del mismo puedan ser usados para modificar proteínas experimentalmente. La glicina, por otra parte, no suele ser usada en ingeniería de proteínas ya que su introducción en las cadenas peptídicas suele causar problemas estructurales debido al incremento de la flexibilidad de la cadena.

Hasta ahora vimos que el docking proteína-proteína tiene la ventaja de poder realizar predicciones bastante precisas sin necesidad de conocer el sitio de interacción con exactitud. Sin embargo, estos métodos también poseen sus limitaciones. Como ya analizamos anteriormente, el docking no suele tener en cuenta la flexibilidad de las proteínas durante la fase de muestreo, y durante la fase de filtrado la flexibilidad usualmente se trata de forma limitada para reducir los cálculos. Esto puede introducir artefactos que afectan la precisión en el caso de complejos donde la flexibilidad sea importante para la unión. Otro elemento a tener en cuenta es que al no tener ninguna referencia del sitio de interacción, el docking no siempre localiza adecuadamente la superficie de interacción entre proteínas. Dependiendo del método de búsqueda y la función de puntuación usada, el programa puede predecir complejos en los que las proteínas están interaccionando de forma totalmente diferente al complejo nativo, y este tipo de error no puede ser resuelto con ningún método de refinado. Por último, los métodos de búsqueda y las funciones de puntuación suelen usar aproximaciones para reducir el coste computacional de los métodos, lo que muchas veces afecta la precisión de los mismos.

Debido a esto, a la hora de analizar las predicciones de un docking proteína-proteína siempre se recomienda mirar los resultados con escepticismo y no aceptar las estructuras propuestas como verdaderas. Siempre que sea posible, se debe tratar de usar resultados experimentales para corroborar el modelo obtenido y así tener mayor certeza de que el complejo predicho se corresponde lo mejor posible con la realidad.

En la diapositiva 36 pueden observar algunos programas para realizar docking proteína-proteína con sus correspondientes métodos de búsqueda y funciones de puntuación. Para la clase práctica usaremos el programa **ClusPro**, el cual posee un buen balance entre precisión, velocidad y facilidad de uso.

A fin de conocer la efectividad de los diferentes programas de predicción de interacciones proteína-proteína, todos los años se lleva a cabo un experimento masivo de predicción denominado Critical Assessment of PRredicted Interactions (**CAPRI**). Este experimento masivo es similar al CASP en el hecho de que los investigadores deben tratar de modelar uno o varios complejos proteína-proteína cuya estructura 3D ha sido resuelta por técnicas experimentales pero aún no ha sido publicada. Una vez hecha la predicción, se hace pública la estructura 3D y se puede comparar cuan precisos fueron los programas de predicción. Sin embargo, a diferencia del CASP, que es cada dos años, cada año se realizan entre 1 y 4 rondas de CAPRI con entre 1 y 5 proteínas blanco cada una. Hasta el 2020 se habían realizado 47 rondas CAPRI y se habían evaluado en total 159 complejos.

En esta conferencia vimos la importancia de las interacciones proteína-proteína y los métodos que podemos usar la predecir la estructura 3D de estas interacciones. Sin embargo, ¿Son estas las únicas interacciones que pueden presentar las proteínas? No, como ya sabemos de cursos anteriores, las proteínas pueden interaccionar con una gran variedad de moléculas pequeñas como hormonas, reguladores alostéricos, metabolitos, medicamentos y neurotransmisores. En la próxima conferencia analizaremos métodos bioinformáticos de predicción de complejos formados por proteínas y moléculas pequeñas.